

IF29 - Traitement de données (Data Analytics) - Semestre P25

Projet : Comparaison de deux méthodes de classification de profils de X (ex. Twitter)

1. Contexte et objectif

Ce projet vise à expérimenter et comparer deux approches de classification appliquées à la détection de profils « atypiques » sur Twitter par : une approche non-supervisée et une approche supervisée.

Vous avez reçu deux jeux de données :

- **Tweet_Worldcup.zip** : jeu complet
- **Tweet_Worldcup_200Tweets.zip** : un sous-ensemble de 200 fichiers pour vos tests

Chaque groupe projet choisira et mettra en œuvre deux algorithmes de Machine Learning (un non-supervisé et un supervisé) pour la détection de profils suspects. Une étude comparative des résultats sera réalisée sur les dimensions jugées pertinentes.

Qu'entend-on par "profil atypique" ? Libre à vous d'en proposer une définition argumentée à partir des données et de la documentation scientifique (par exemple des bots, des spammeurs, ou des profils manipulant l'information- fake news).

2. Livrables attendus

L1 : Rapport de projet

- 20-25 pages (hors annexes)
- Contenant : introduction, description des données, méthodologie, résultats, discussion, limites, bibliographie

L2 : Code documenté

- Organisé dans un dépôt GitHub ou autre plateforme
- README expliquant l'installation, l'utilisation, les dépendances
- Code commenté et structuré (Jupyter Notebook ou script Python)

L3 : Soutenance orale

- Durée : 10-15 minutes
- Support visuel (diaporama)
- Contenu : problématique, démarche, résultats, apprentissages

L4 : Description des rôles au sein de l'équipe-projet

- Chaque membre de l'équipe décrira le ou les rôles qu'il a joués dans le projet, en lien avec les rôles (Data Engineer, Data Architect, Data Analyst, Data Cleaner, Chief Data Officer, Data Protection Officer, Dataviz Expert, ML Project Manager, etc.) croisés avec les cinq principales tâches autour d'un modèle de machine learning :
 - Données d'entrée
 - Paramètres d'entrée
 - Sorties cibles / Résultats
 - Métriques d'état du modèle
 - Politique de gestion du modèle

3. Déroulement suggéré

Étape 1 : Préparation des données

- Extraction et prise en main des données (format JSON, CSV...)
- Compréhension des variables disponibles
- Identification des indicateurs métier utiles
- Choix d'un format de stockage (MongoDB recommandé pour les gros volumes ou les formats semi-structurés)

Étape 2 : Exploration et feature engineering (quelques suggestions)

- Création d'attributs dérivés du graphe social, du contenu et du comportement, par exemple :
 - Nombre de followers, nombre de comptes suivis, ratio
 - Fréquence de publication, nombre moyen d'URL, hashtags, mentions
 - Nombre de retweets, réponses, longueur moyenne des tweets
 - Scores d'agressivité et de visibilité (exemple : SPOT)
- Normalisation, réduction de dimension si nécessaire (PCA, t-SNE...)
- Visualisation des données sous différents angles (graphes, histogrammes, nuages de points)
- Identification de corrélations ou comportements atypiques

Ressources complémentaires pour le choix des attributs :

Ferrara, E., Varol, O., Davis, C., Menczer, F., & Flammini, A. (2016). *The rise of social bots*. Communications of the ACM, 59(7), 96-104.

Chu, Z., Gianvecchio, S., Wang, H., & Jajodia, S. (2012). *Detecting automation of Twitter accounts: Are you a human, bot, or cyborg?* IEEE Transactions on Dependable and Secure Computing, 9(6), 811-824.

Varol, O., Ferrara, E., Davis, C. A., Menczer, F., & Flammini, A. (2017). *Online human-bot interactions: Detection, estimation, and characterization*. In Proceedings of ICWSM, 280-289.

Étape 3 : Choix et mise en œuvre des modèles

- Choix d'un algorithme **supervisé** (exemple : Random Forest, SVM, Logistic Regression)
- Choix d'un algorithme **non-supervisé** (exemple : K-means, DBSCAN, clustering hiérarchique)
- Justification théorique du choix des deux approches
- Modélisation et Implémentation des deux pipelines d'entraînement et d'évaluation

Étape 4 : Expérimentation et analyse comparative

- Exécution des deux modèles
- Comparaison des résultats selon plusieurs dimensions (précision, rappel, F1, temps de calcul, robustesse...)
- Discussion des apports, limites et pistes d'amélioration

Étape 5 : Rédaction du rapport, préparation de la soutenance et élaboration du livrable L4

4. Critères d'évaluation

Critère	Poids indicatif
Qualité et profondeur de l'exploration des données	20%
Pertinence des choix méthodologiques	20%
Qualité de l'implémentation technique	20%
Analyse critique et comparaison	20%
Clarté et structure des livrables	20%

Remarque : n'hésitez pas à poser des questions ou demander des précisions au fur et à mesure de votre avancement.